

2. Grundlagen

2.1 Biometrische Gesichtserkennung & Sicherheitsrelevanz

Kurze Zusammenfassung des Kapitels

2.1.1 Definition und Einsatzgebiete

Biometrische Systeme dienen der Identifikation oder Verifikation einer Person anhand bestimmter körperlicher Merkmale. Dabei werden charakteristische Merkmale wie Iris, Fingerabdruck, Stimme oder Gesicht genutzt, um eine Person eindeutig zu identifizieren. Im Bereich der Gesichtserkennung haben sich Face Recognition Systems (FRS) in den letzten Jahren als eines der am häufigsten eingesetzten biometrischen Verfahren etabliert. FRS werden in verschiedenen Bereichen eingesetzt, darunter die Entsperrung von Smartphones, die Kriminalitätsbekämpfung, Grenzkontrollen, öffentliche Veranstaltungen sowie unbemannte und autonome Fahrzeuge. FRS ist in der Lage, Personen automatisch anhand von Kamerabildern zu identifizieren, ohne dass ein manueller Eingriff erforderlich ist [2]. Insbesondere bei Reisedokumenten wie dem ePass kommen FRS zum Einsatz, da hier eine Identitätsprüfung an Grenzkontrollen erfolgt [1].

2.1.2 Funktionsweise eines automatischen Gesichtserkennungssystems

Ein typisches Gesichtserkennungssystem durchläuft drei wesentliche Schritte: die Gesichtsdetektion, die Merkmalsextraktion und die Gesichtserkennung. Dabei muss das System unter verschiedenen Bedingungen zuverlässig arbeiten, wie bei wechselnden Lichtverhältnissen oder unterschiedlichen Kopfpositionen. In der Abbildung 1 wird der Vorgang eines Gesichtserkennungssystems genau erklärt [2].




Abbildung 1: Ablauf eines Gesichtserkennungssystems

Es gibt ein Inputbild, welches von der ersten Etappe (Gesichtsdetektion) analysiert wird. In diesem Schritt versucht das System das Gesicht auf dem Bild zu lokalisieren und zu prüfen, ob es generell ein Gesicht auf dem Bild gibt. Wie wir zuvor erwähnt haben, gibt es bestimmte Bedingungen, wie Lichtverhältnisse oder Gesichtsausdrücke, die die Detektion erschweren können. Um dieses Problem zu umgehen, werden verschiedene „Pre-processing“ Methoden angewendet, wie der Viola-Jones-Detektor, Histogram of Oriented Gradients (HOG) und Principal Component Analysis (PCA) [2].

Nachdem das Modell auf dem Bild erfolgreich das Gesicht detektiert hat, werden nun die Merkmale extrahiert. In diesem Schritt werden charakteristische Eigenschaften

des Gesichts identifiziert, beispielsweise die Position und Form von Augen, Nase und Mund sowie deren geometrische Beziehungen zueinander. Für die Merkmalsextraktion existieren verschiedene Verfahren. Klassische Ansätze wie Eigenface, Local Binary Patterns (LBP) oder HOG basieren auf manuell definierten Merkmalen. Aus diesen Eigenschaften entsteht ein Merkmalsvektor, der das Gesicht beschreibt. Das entstandene Merkmalsvektor ist die Grundlage für den anschließenden Vergleich mit anderen Vektoren [2].

Im letzten Schritt der Gesichtserkennung werden die extrahierten Merkmalsvektoren aus dem Referenzbild genutzt, um die Person entweder zu identifizieren oder zu verifizieren. Bei der Identifikation werden die Vektoren des Eingabebildes mit den Vektoren aus einer Datenbank verglichen. Das System sucht dabei die wahrscheinlichste Übereinstimmung, um die abgebildete Person zu identifizieren. Diese Methode kommt häufig in der Kriminaltechnik zum Einsatz, wenn man eine unbekannte Person identifizieren möchte. Beim Verifikation wird das Eingabebild mit einem einzigen Referenzbild verglichen. Hierfür werden die Vektoren verglichen und überprüft, ob die übereinstimmen. Ein typisches Beispiel ist die Identitätsprüfung an einer Grenzkontrolle, bei der das Live-Foto mit dem Passfoto abgeglichen wird [2].

2.2 Face Morphing & Bedrohungspotenzial

Kurze Zusammenfassung des Kapitels

2.2.1 Definition und Entstehung eines Morphs

Face Morphing bezeichnet den Prozess, bei dem zwei oder mehrere Gesichter miteinander kombiniert werden. Dabei werden bestimmte Gesichtsmerkmale, wie Augen, Nase und Mund bspw. von zwei Personen so überlagert, dass ein neues Bild entsteht, welches die Merkmale beider Personen gleichzeitig übernimmt. Dies erzeugt die Illusion, dass das gemorphte Bild sowohl Person A als auch Person B ähnelt. In der Realität führt dies dazu, dass automatische Gesichtserkennungssysteme das gemorphte Bild als gültige Übereinstimmung für beide Personen akzeptieren. [1]




Abbildung 2: Beispielszenario eines Morphingangriffs an einer Grenzkontrolle [1]

Das folgende Szenario verdeutlicht die potenzielle Gefahr eines Morphingangriffs. In diesem Beispiel haben wir zwei Akteure. Person A, welche die Rolle des kriminellen Akteurs einnimmt, und Person B, welche den Komplizen darstellt. Gemeinsam erstellen beide Akteure ein gemorphtes Bild, welches die Gesichtsmerkmale beider Personen aufweist. Person B reicht dieses Bild bei der Passbehörde ein und erhält einen offiziellen Pass. Da das gemorphte Bild auch die Merkmale von Person A enthält, kann Person A diesen Pass nutzen, um Grenzkontrollen zu überqueren, ohne Verdacht zu erregen. Diese Arten von Morphing Attacken sind mittlerweile leicht umzusetzen, da es viele Möglichkeiten gibt Gesichter zu morphen ohne einen technischen Hintergrund zu haben. [1]

2.2.2 Landmark-basiertes vs GAN-basiertes Morphing

Face Morphing kann auf verschiedene Weisen realisiert werden. Die beiden gebräuchlichsten Ansätze sind das landmark-basierte Morphing und das GAN-basierte Morphing. Beide Methoden unterscheiden sich fundamental in ihrer Herangehensweise und der Qualität der erzeugten Morphs [1].




Abbildung 3: Proband aus dem Datensatz Face Research Lab London Set (figshare). Landmarks wurden mit dlib generiert (eigene Darstellung)

Beim landmark-basierten Morphing werden zunächst markante Gesichtspunkte mit sogenannte Landmarks in beiden Ausgangsbildern identifiziert, wie man in Abbildung 3 sehen kann. Diese Punkte markieren charakteristische Gesichtsmerkmale wie Augen, Nase und Mund. Anschließend werden die Bilder durch geometrische Transformation so verformt, dass die Landmarks beider Gesichter auf eine durchschnittliche Position gebracht werden. Dieser Prozess wird als „Warping“ bezeichnet. Zum Schluss werden die Farbwerte der transformierten Bilder miteinander vermischt. Allerdings erscheinen bei landmark-basierten Morphing bei scharfen Kanten, wie Augen, Mund und Nase einige Bildstörungen, die als „Ghosting-Effekt“ bekannt sind. Dieses Phänomen tritt auf, wenn die Ausgangsbilder starke

unterschiedliche Gesichtszüge haben. Um diese Bildstörungen zu entfernen, verwendet man ein Verfahren, was unter „Post-Processing“ bekannt ist. Hierbei werden Bildstörungen, die in bestimmten Bereichen auftreten geglättet und geschärft [1].

Durch die schnelle Entwicklung der Deep-Learning-Modelle ist es auch möglich Morphing Bilder mit GAN-basierte Methoden zu erstellen. Dabei werden die Ausgangsbilder in einen hochdimensionalen Merkmalsraum projiziert und durch mathematische Operationen zu einem neuen Bild kombiniert. Dieses neue künstlich erzeugte Bild weist somit Eigenschaften von Person-A und Person-B. Der entscheidende Vorteil dieser Methode ist die deutlich höhere Bildqualität. GAN-basierte Morphs weisen kaum sichtbare Bildstörungen auf und wirken natürlicher als landmark-basierte Morphs. Allerdings erfordert diese Methode ein vortrainiertes GAN-Modell und ist technisch anspruchsvoller. Aus Sicht der Angriffserkennung stellen GAN-basierte Morphs die größere Bedrohung dar. Während landmark-basierte Morphs aufgrund ihrer Bildstörungen sowohl von menschlichen Beobachtern als auch von automatischen Detektionssystemen erkannt werden können, sind GAN-basierte Morphs deutlich schwerer zu identifizieren. Venkatesh et al. zeigen, dass insbesondere GAN-basierte Architekturen wie MIPGAN-I und MIPGAN-II eine deutlich höhere Bildqualität liefern und somit eine erhöhte Bedrohung für Gesichtserkennungssysteme darstellen [1].

Morphing Methoden:	Vorteile	Nachteile
Landmarks	- Verfügbarkeit von Open-Source-Tools. - Erzeugt qualitativ hochwertige Morphing-Bilder. - Täuscht kommerzielle Gesichtserkennungssysteme (COTS FRS) erfolgreich. - Einfache und nahtlose Generierung gemorphter Bilder durch einen automatisierten Prozess.	-Erfordert manuelles Eingreifen, um eine hohe Qualität der Morph-Generierung sicherzustellen. -Benötigt Nachbearbeitung (Post-Processing), um Ghosting-Effekte und Doppelkonturen zu reduzieren. -Die Auswahl der Testpersonen (Data Subjects) ist entscheidend, um das FRS zu täuschen.
Deep-Learning-Modelle	- Kein manuelles Eingreifen erforderlich. - Nahtlose Generierung mit akzeptabler Bildqualität. - Zeigt keine Doppelkonturen in den generierten Bildern. - Einigermaßen erfolgreich darin, kommerzielle Gesichtserkennungssysteme (COTS FRS) zu täuschen. - Mehrere Open-Source-Tools verfügbar.	- Erfordert ein komplexes Lernverfahren. - Erzeugt nicht immer qualitativ hochwertige Morph-Bilder. - Sehr anfällig für geometrische Verzerrungen. - Erfordert eine sorgfältige Vorauswahl der Testpersonen basierend auf Alter, Geschlecht und ethnischer Zugehörigkeit

Tabelle 1: Vergleich der Vor- und Nachteile von Landmark-basierten und Deep-Learning-basierten Morphing-Verfahren (Eigene Übersetzung in Anlehnung an [1]).

Tabelle 1 verdeutlicht, dass landmark-basierte Methoden eine hohe visuelle Qualität liefern, jedoch mehr manuelle Arbeit und Nachbearbeitungen erfordern. Deep-Learning-Ansätze wie GANs automatisieren den Prozess und vermeiden typische Bildstörungen wie Geisterbilder, sind dafür jedoch technisch komplexer und anfälliger für geometrische Verzerrungen.[1]

Für diese Arbeit wird das landmark-basierte Morphing verwendet, da sich die einzelnen Zwischenschritte, wie die Extraktion der Landmarks und die geometrische Berechnung des Warpings nachvollziehen und überprüfen lassen. Bei GAN-basierten Verfahren hingegen findet die Generierung im latenten Raum statt, der als sogenannte „Black Box“ fungiert und somit eine direkte Analyse der Zwischenschritte nicht ermöglicht. Darüber hinaus erfordert GAN-basiertes Morphing leistungsstarke GPUs und vortrainierte Modelle, was den Rahmen dieser Arbeit übersteigt.

2.2.3 MAD (Morphing Attack Detection)

Mit zunehmender Bedrohung durch Face Morphing wurde ein eigenes Forschungsfeld MAD(Morphing Attack Detection) etabliert, die ihren Fokus darauf legt gemorphte Bilder zu erkennen. MAD-Verfahren lassen sich in zwei Hauptkategorien unterteilen. Single-Image MAD (S-MAD) und in Differential MAD (D-MAD). S-MAD analysiert ein einzelnes Bild und entscheidet dementsprechend, ob es sich um ein gemorphtes oder ein bona fide Bild handelt. Bei dem vorher genannten Szenario von Abbildung 1, wird das gemorphte Bild online bei der Passbeantragung eingereicht. Hier muss S-MAD nun eine Entscheidung treffen, indem es das eingereichte Bild auf Bildstörungen, Texturmuster oder Frequenzanomalien untersucht [1].




Abbildung 4: Szenario von S-MAD bei einer Passbeantragung

Der Prozess von D-MAD vergleicht zwei Bilder miteinander. Hierbei wird bei der ABC (Automated Border Control) Grenzkontrolle eine Liveaufnahme von der Person gemacht und diese Aufnahme wird mit dem Bild auf dem Pass verglichen. Aus beiden Bildern werden biometrische Merkmale extrahiert und miteinander verglichen, um zu beurteilen, ob es sich um dieselbe Person handelt oder ob das Passfoto ein Morph ist. Abbildung 5 illustriert diesen Vorgang [1].




Abbildung 5: D-MAD Detektion an einer ABC (Automated Border Control) Szenario

Die vorliegende Arbeit verfolgt jedoch einen anderen Ansatz. Anstatt ein Detektionssystem zu entwickeln, das gemorphte Bilder erkennt, wird die Robustheit bestehender Klassifikationsmodelle (DeepFace und CLIP) gegenüber gemorphten Bildinhalten untersucht.

2.3 Werkzeuge und Frameworks

2.3.1 dlib: Gesichtsdetektion und Landmark-Extraktion

Für die Gesichtsdetektion und die Extraktion der Landmarks wird in dieser Arbeit die Open-Source-Bibliothek dlib verwendet. dlib ist eine in C++ entwickelte Bibliothek für maschinelles Lernen und Computer Vision und stellt eine Vielzahl von Algorithmen bereit, beispielsweise für Klassifikation, Regression und Anomaliedetektion. Zudem bietet dlib eine Python-Schnittstelle, die eine einfache Integration in eigene Projekte ermöglicht und die Bibliothek sowohl für akademische Forschungsprojekte als auch für industrielle Anwendungen attraktiv macht [3].

Während Menschen Gesichter ohne Probleme erkennen, stellt die automatische Detektion durch einen Computer eine erhebliche Herausforderung dar. Dabei spielt die Position, Beleuchtungsverhältnissen, wechselnden Gesichtsausdrücken usw. eine wichtige Rolle, da dies alles bei der Detektion zu Problemen führen kann. Aus diesem Grund werden algorithmische Verfahren wie HOG (Histogram of Oriented Gradients) eingesetzt. Es existieren jedoch auch alternative Ansätze wie Haar-Like-Features oder LBP, welche ebenfalls Gesichter in Bildern detektieren können. HOG erweist sich in dieser Kategorie jedoch als am robustesten, da diese eine Detektionsrate von 92.68% hat. HOG analysiert lokale Gradientenmuster im Bild, also Bereiche, in denen sich die Helligkeit stark verändert und ermöglicht so die Lokalisierung von Gesichtern anhand ihrer charakteristischen Strukturen. Beim HOG-Verfahren wird das Bild zunächst in $N \cdot N$ kleine Zellen unterteilt. Für jeden Pixel innerhalb einer Zelle werden anschließend die Helligkeitsunterschiede zu den benachbarten Pixeln in horizontaler und vertikaler Richtung berechnet. Aus diesen Helligkeitsunterschieden ergeben sich die Richtung und Stärke des Gradienten, also die Information, in welche Richtung sich die Helligkeit ändert und wie ausgeprägt diese Änderung ist. Pro Zelle werden diese Gradienten in einem lokalen Histogramm der Gradientenrichtungen zusammengefasst [4].




Abbildung 6: HOG-Verfahren

Beispielsweise zeigt sich an den Konturen einer Augenbraue ein starker vertikaler Gradient, da die dunkle Augenbraue einen deutlichen Helligkeitsunterschied zur helleren Stirn aufweist. Solche charakteristischen Helligkeitsmuster werden von HOG erfasst und ermöglichen die Identifikation typischer Gesichtsstrukturen.

Um das gesamte Bild auf Gesichter zu untersuchen, wird das Bild mit einem Detektionsfenster an allen Positionen und in allen möglichen Größen vollständig durchläuft. Für jeden Bildausschnitt innerhalb dieses Fensters wird ein HOG-Deskriptor berechnet und anschließend von einer Support Vector Machine (SVM) klassifiziert. Die SVM ist ein vortrainiertes Modell, das anhand vieler Trainingsbeispiele gelernt hat, wie die Gradientenmuster eines Gesichts im Vergleich zu Nicht-Gesichtern aussehen. Erkennt die SVM in einem bestimmten Bildausschnitt ein Gesicht, wird dessen Position als Bounding Box ausgegeben. Auf diese Weise lokalisiert dlib das Gesicht im Bild [4].

Nachdem wir jetzt wissen, wo sich das Gesicht im Bild befindet, müssen wir die Landmarks an den richtigen Stellen generieren. Um die Landmarks an den markanten Stellen wie Augen, Nase und Mund zu generieren, nutzt dlib das Verfahren des Face Alignment, das auf einem Ensemble von Regressionsbäumen basiert. Da das System zu Beginn nicht weiß, wo genau sich die Gesichtsmerkmale im Bild befinden, startet es mit einer Initialschätzung. Diese entspricht typischerweise dem durchschnittlichen Landmarkmuster aller Trainings-bilder, auf denen das dlib Modell trainiert wurde. Anschließend werden die geschätzten Landmarkpositionen schrittweise an die tatsächlichen Gesichtsmerkmale angepasst. Dieser Vorgang erfolgt über eine Kaskade von Regressionsbäumen, die in jeder Iteration die Pixelintensitäten in der Umgebung der aktuellen Landmarkpositionen analysieren. Auf Basis dieser Analyse berechnen die Bäume Verschiebungswerte für jeden Landmark-Punkt, sodass dieser näher an die wahre Position rückt. Das Verfahren wird in mehreren Stufen wiederholt, bis sich die Landmarks präzise an die tatsächlichen Gesichtskonturen angepasst haben [5].




Abbildung 7: Ablauf des Face Alignments in dlib: Sukzessive Anpassung der Landmarks über mehrere Kaskadenschritte

Abbildung 7 veranschaulicht diesen Prozess beispielhaft. In Schritt (a) ist zu erkennen, dass das Durchschnittsgesicht zunächst nur grob über dem tatsächlichen Gesicht platziert wird. Durch die fortschreitenden Iterationen der Kaskade über die Schritte (b) bis (d) passen sich die Punkte immer weiter an. Bei Schritt (e) haben die Landmarks schließlich die markanten Kanten und Strukturen erreicht und stimmen nahezu perfekt mit der tatsächlichen Form, der Ground Truth (f), überein [5].

2.3.2 OpenCV: Delaunay-Triangulierung und Warping

OpenCV (Open Source Computer Vision Library) ist eine Open-Source-Bibliothek für Computer Vision und Bildverarbeitung, die ursprünglich von Intel entwickelt wurde. Sie umfasst über 2500 optimierte Algorithmen und wird sowohl in akademischen als auch industriellen Anwendungen eingesetzt, beispielsweise zur Objektdetektion, Gesichtserkennung und Videoanalyse [6].

In dieser Arbeit wird OpenCV zur Bildverarbeitung und geometrischen Transformation eingesetzt, insbesondere für die Delaunay-Triangulation und das Warping der gemorphten Bilder.

Um das Warping-Verfahren umzusetzen, müssen die Landmarks zunächst in ein Netz aus Dreiecken zerlegt werden [1]. Dazu wird die Delaunay-Triangulation eingesetzt, ein geometrisches Verfahren, das die generierten Landmarks in gleichmäßige Dreiecke unterteilt. Dieses Verfahren maximiert den kleinsten Innenwinkel jedes Dreiecks, um dünne oder extrem lange Dreiecke zu vermeiden [7]. Beispielsweise wäre ein Dreieck mit Innenwinkeln von 175° , 3° und 2° ungünstig, da die Winkel extrem ungleich verteilt sind. Idealerweise sind die Innenwinkel annähernd gleichgroß. Abbildung 8 zeigt, dass die Innenwinkel der Dreiecke gleichmäßig verteilt sind.




Abbildung 8: Delaunay-Triangulation eines Gesichts mit 68 Landmarks. (Eigene Darstellung)

Diese Dreiecke bilden die Grundlage für das anschließende Warping. Das Warping-Verfahren ist eine geometrische Transformation, die die räumliche Struktur eines Bildes verändert. Im Kontext des triangulationsbasierten Face Morphing werden Dreiecke verwendet, um das Warping umzusetzen. Beim Morphing werden zwei Operationen kombiniert, Warping für die geometrische Transformation und Cross-Dissolve für die Überblendung der Farben. Dabei ändern sich die Farbwerte jedes

Pixels vom ersten zum zweiten Bild. Das Ergebnis ist ein fließender Übergang zwischen den beiden Originalbildern [7].

2.3.3 DeepFace: Architektur und Funktionsweise

DeepFace wurde von FaceBook entwickelt...

IEEE-Zitierstil

[1] Venkatesh, S.; Ramachandra, R.; Raja, K.; Busch, C.: Face Morphing Attack Generation and Detection: A Comprehensive Survey.

<https://ieeexplore.ieee.org/abstract/document/9380153>

[2] . Kortli, M. Jridi, A. Al Falou, M. Atri: "Face Recognition Systems: A Survey", Sensors, Vol. 20, No. 2, 342, 2020.DOI: 10.3390/s20020342

<https://www.mdpi.com/1424-8220/20/2/342>

[3]Der Hamudi und dies das Entwickler von dlib 2009

<https://www.jmlr.org/papers/volume10/king09a/king09a.pdf>

[4]

<https://ieeexplore.ieee.org/document/8893214/>

[5]

<https://ieeexplore.ieee.org/document/6909637>

[6]

<https://ieeexplore.ieee.org/document/6240859>

[7]

Aloraibi, A. Q. (2023): „Image Morphing Techniques: A Review". Technium, Vol. 9, S. 41-53.

[https://www.researchgate.net/profile/Alyaa-](https://www.researchgate.net/profile/Alyaa-Aloraibi/publication/389030873_ID8699_image_morphing/links/67b10437207c0c20fa8ae703/ID8699-image-morphing.pdf)

[Aloraibi/publication/389030873_ID8699_image_morphing/links/67b10437207c0c20fa8ae703/ID8699-image-morphing.pdf](https://www.researchgate.net/profile/Alyaa-Aloraibi/publication/389030873_ID8699_image_morphing/links/67b10437207c0c20fa8ae703/ID8699-image-morphing.pdf)